UTTT
Universidad Tecnológica de Tula Tepeji

UNIVERSIDAD TECNOLÓGICA DE TULA-TEPEJI
1991

UNIVERSIDAD TECNOLÓGICA DE TULA-TEPEJI

ACTIVIDAD DE EVALUACIÓN 1

EXPLORACIÓN Y DIAGNÓSTICO TÉCNICO DEL CONJUNTO DE DATOS

Unidad II



Alumno:	Mark Alan Moya Galindo
Asignatura:	Extracción de Conocimiento en Bases de Datos
Proyecto:	Predicción de demanda en un sistema de bicicletas compartidas
Dataset:	Bike Sharing
Docente:	Ing. José Luis Herrera Gallardo
Periodo:	Recursamiento 2026

Proyecto No. 3

TECNOLOGÍA PARA UN MEJOR FUTURO

1. Identificacion del dataset

Nombre del proyecto	Prediccion de demanda en un sistema de bicicletas compartidas
Dataset asignado	Bike Sharing
Archivo principal	hour.csv
Fuente original	UCI Machine Learning Repository
Registros observados	17,379
Variables	17
Formato	CSV estructurado

Cada fila representa una observacion horaria del sistema de bicicletas. La informacion combina fecha, temporada, hora, tipo de dia, condiciones meteorologicas y conteos de usuarios. El archivo original permanece sin modificaciones en **data/raw/hour.csv**.

2. Carga y exploracion inicial

El notebook utiliza **pandas.read_csv()** y las instrucciones **df.head()**, **df.shape**, **df.columns**, **df.info()**, **df.dtypes** y **df.describe()** para revisar la estructura, los tipos de datos y la estadistica preliminar.

La revision confirma 17,379 registros y 17 variables. La mayoria de columnas son numericas; **dteday** se conserva como texto durante esta actividad porque aun no corresponde realizar transformaciones.

3. Diccionario de datos

Se clasificaron las variables segun su naturaleza y posible utilidad.

Variable	Descripcion	Tipo	Clasificacion	Unidad	Utilidad
instant	Indice del registro	int64	Cuant. discreta	Registro	Identificacion
dteday	Fecha de observacion	object	Temporal	Fecha	Analisis temporal
season	Temporada 1-4	int64	Cualitativa nominal	Categoria	Temporada
yr	Ano 0/1	int64	Cualitativa binaria	Categoria	Comparar anos
mnth	Mes 1-12	int64	Cualitativa ordinal	Mes	Patron mensual
hr	Hora 0-23	int64	Cualitativa ordinal	Hora	Patron horario
holiday	Dia festivo	int64	Cualitativa binaria	Categoria	Festivos
weekday	Dia semanal 0-6	int64	Cualitativa nominal	Categoria	Patron semanal
workingday	Dia laborable	int64	Cualitativa binaria	Categoria	Tipo de dia
weathersit	Clima 1-4	int64	Cualitativa ordinal	Categoria	Clima
temp	Temperatura normalizada	float64	Cuant. continua	Normalizada	Predictor
atemp	Sensacion termica norm.	float64	Cuant. continua	Normalizada	Predictor
hum	Humedad normalizada	float64	Cuant. continua	Normalizada	Predictor
windspeed	Viento normalizado	float64	Cuant. continua	Normalizada	Predictor
casual	Usuarios casuales	int64	Cuant. discreta	Usuarios	Descriptiva
registered	Usuarios registrados	int64	Cuant. discreta	Usuarios	Descriptiva
cnt	Total de rentas	int64	Cuant. discreta	Rentas	Objetivo regresion

4. Tipo y fuente de los datos

El dataset es **estructurado**. Combina datos **transaccionales/operacionales** derivados del uso del sistema con datos **ambientales/meteorologicos** como temperatura, humedad, viento y situacion climatica.

5. Diagnostico de calidad

5.1 Valores faltantes

La instruccion **df.isnull().sum()** confirma que todas las variables presentan **0 valores faltantes**.

Indicador	Resultado	Interpretacion
Valores faltantes	0	No requiere imputacion
Filas duplicadas	0	No requiere eliminacion

5.2 Registros duplicados

La instruccion **df.duplicated().sum()** devuelve **0 registros duplicados**. Si aparecieran en una version futura, se revisarian fecha, hora y demas campos antes de considerar su eliminacion.

5.3 Comprobaciones de consistencia

Comprobacion	Resultado
season entre 1 y 4	Cumple
yr entre 0 y 1	Cumple
mnth entre 1 y 12	Cumple
hr entre 0 y 23	Cumple
weekday entre 0 y 6	Cumple
weathersit entre 1 y 4	Cumple
temp/atemp/hum/windspeed entre 0 y 1	Cumple
conteos no negativos	Cumple
cnt = casual + registered	Cumple

6. Analisis estadistico inicial

Se seleccionaron **cnt**, **temp** y **hum** por su relevancia para el problema de demanda.

Variable	Media	Mediana	Minimo	Maximo	Desv. est.
cnt	189.4631	142.0000	1.0000	977.0000	181.3876
temp	0.4970	0.5000	0.0200	1.0000	0.1926
hum	0.6272	0.6300	0.0000	1.0000	0.1929

La demanda cnt tiene media 189.46, mediana 142 y desviacion estandar 181.39, lo que evidencia una variacion alta entre horarios.

7. Deteccion de valores atipicos

Se utilizo el criterio IQR. Los valores identificados se documentan, pero no se eliminan en esta actividad.

Variable	Q1	Q3	Lim. inf.	Lim. sup.	Atipicos
cnt	40	281	-321.5	642.5	505
temp	0.34	0.66	-0.14	1.14	0
hum	0.48	0.78	0.03	1.23	22
windspeed	0.1045	0.2537	-0.1193	0.4775	342

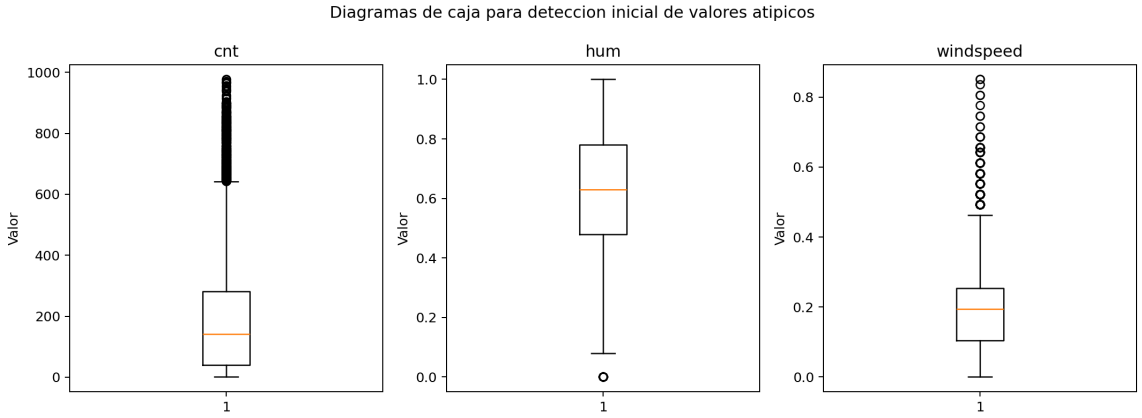


Figura 1. Boxplots para cnt, hum y windspeed.

8. Visualizacion inicial

8.1 Demanda promedio por hora

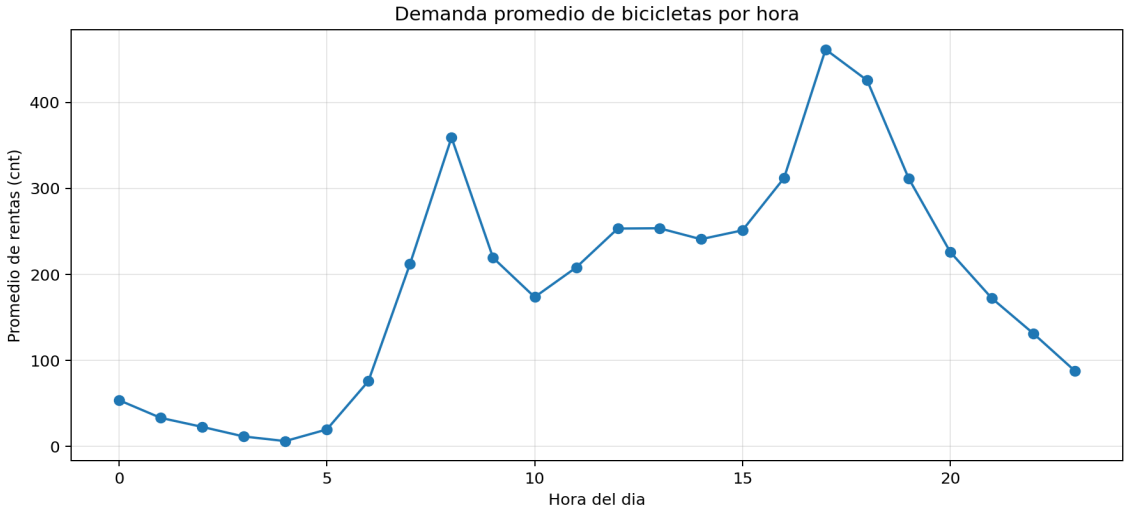


Figura 2. Demanda promedio por hora.

La demanda es baja durante la madrugada y presenta picos importantes alrededor de las 08:00 y entre las 17:00 y 18:00.

8.2 Demanda por clima

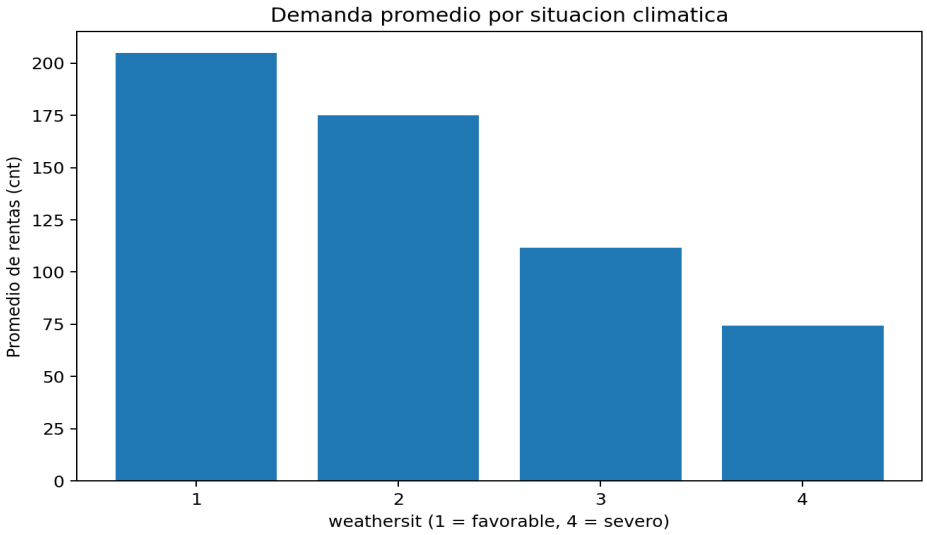


Figura 3. Demanda promedio por situacion climatica.

La demanda disminuye conforme las condiciones climaticas se vuelven mas adversas.

8. Visualizacion inicial - continuacion

8.3 Distribucion de la demanda

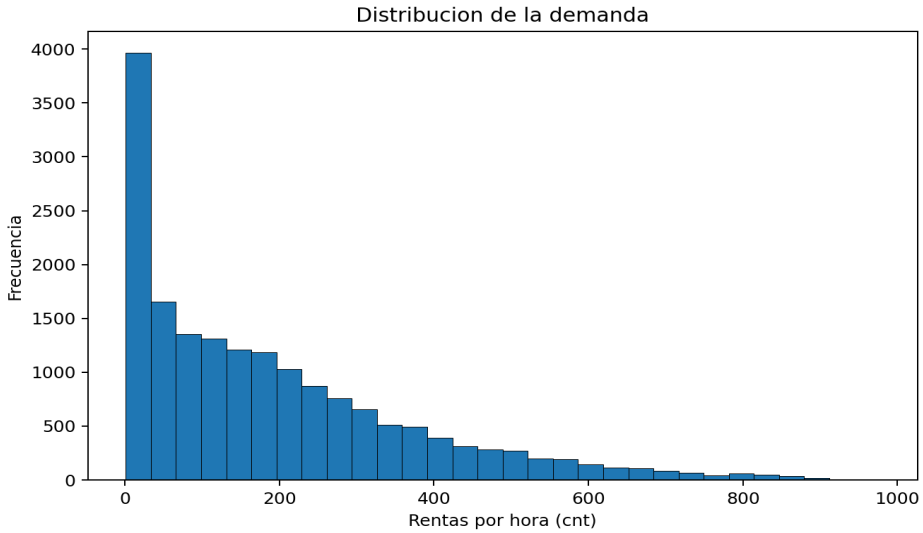


Figura 4. Distribucion de cnt.

La distribucion concentra muchas observaciones de demanda baja o media y una cola de valores altos.

8.4 Temperatura y demanda

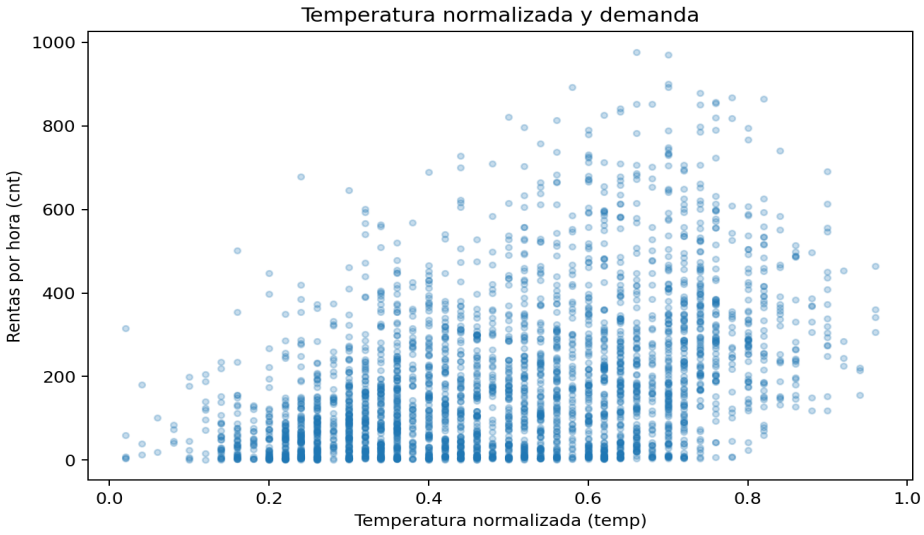


Figura 5. Temperatura normalizada vs demanda.

La temperatura aporta informacion, pero debe combinarse con hora, temporada, tipo de dia y clima.

9. Preparacion para analisis posteriores

Regresion	Objetivo: **cnt**. Entradas sugeridas: hr, weekday, workingday, holiday, season, mnth, yr, weathersit, temp, atemp, hum y windspeed.
Clasificacion	Objetivo propuesto: nivel de demanda con clases baja, media y alta; los cortes se definiran con un criterio reproducible.
Agrupamiento	Variables sugeridas: hr, weekday, season, weathersit, temp, hum, windspeed y cnt para descubrir perfiles de uso.

Prevencion de fuga: casual y registered no deben usarse como predictores directos de cnt porque cnt es la suma de ambos.

10. Conclusion del diagnostico

¿Que informacion contiene el dataset?

Registros horarios de uso de bicicletas, calendario y condiciones meteorologicas.

¿Cual es su nivel general de calidad?

Bueno: no presenta faltantes ni duplicados y las reglas de consistencia se cumplen.

¿Que problemas fueron identificados?

Principalmente posibles valores atipicos por IQR.

¿Que variables requieren tratamiento?

cnt, hum y windspeed requieren revision de extremos; dteday podra convertirse a fecha.

¿Existen valores faltantes?

No.

¿Existen registros duplicados?

No.

¿Existen valores atipicos?

Si: 505 en cnt, 22 en hum y 342 en windspeed por IQR.

¿Que transformaciones seran necesarias?

Conversion de fecha, ingenieria/codificacion de variables y evaluacion justificada de extremos.

¿Los datos son adecuados para continuar?

Si.

¿Que conocimiento podria obtenerse?

Patrones por hora, clima, temporada y tipo de dia; modelos predictivos, de clasificacion y perfiles de uso.

11. Evidencias de ejecucion

Las capturas muestran el dashboard funcionando con el dataset original, sin modificar data/raw/hour.csv.

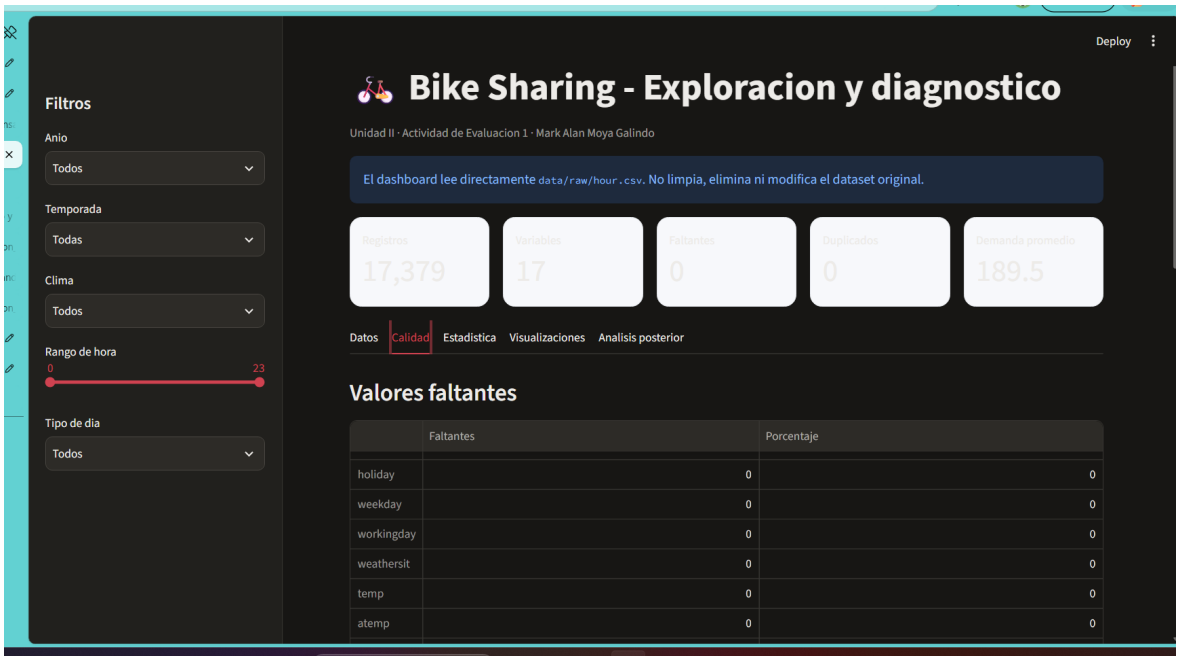


Figura 6. Valores faltantes y resumen general.

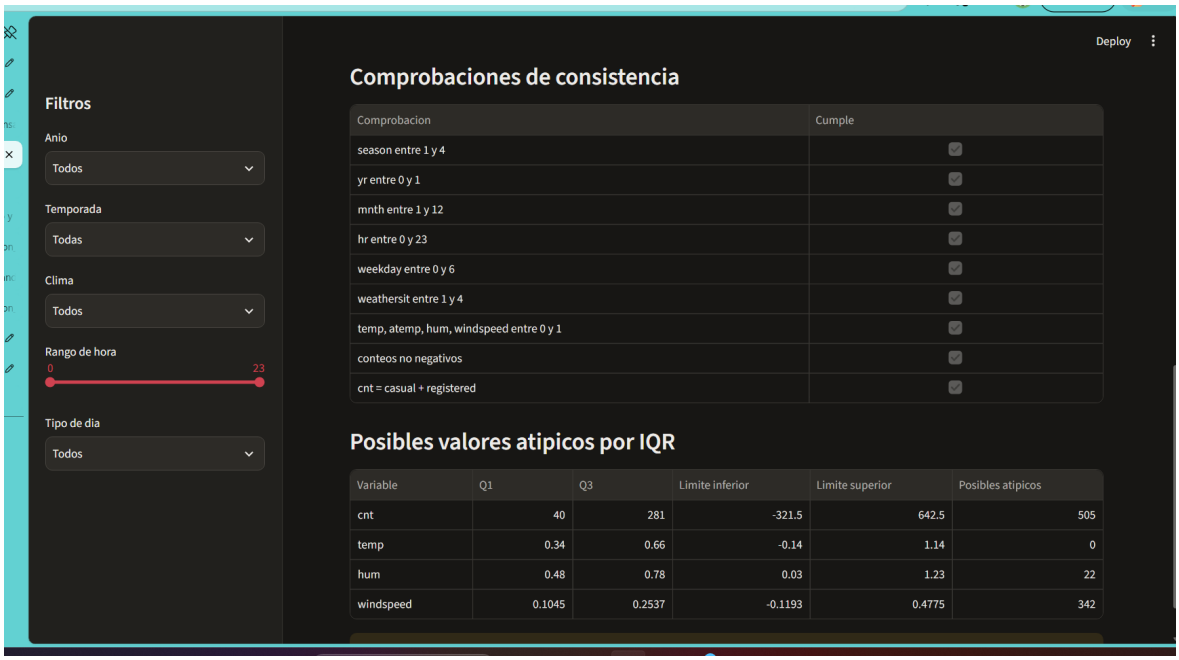


Figura 7. Consistencia y posibles valores atipicos.

11. Evidencias de ejecucion - continuacion



Figura 8. Demanda promedio por hora.

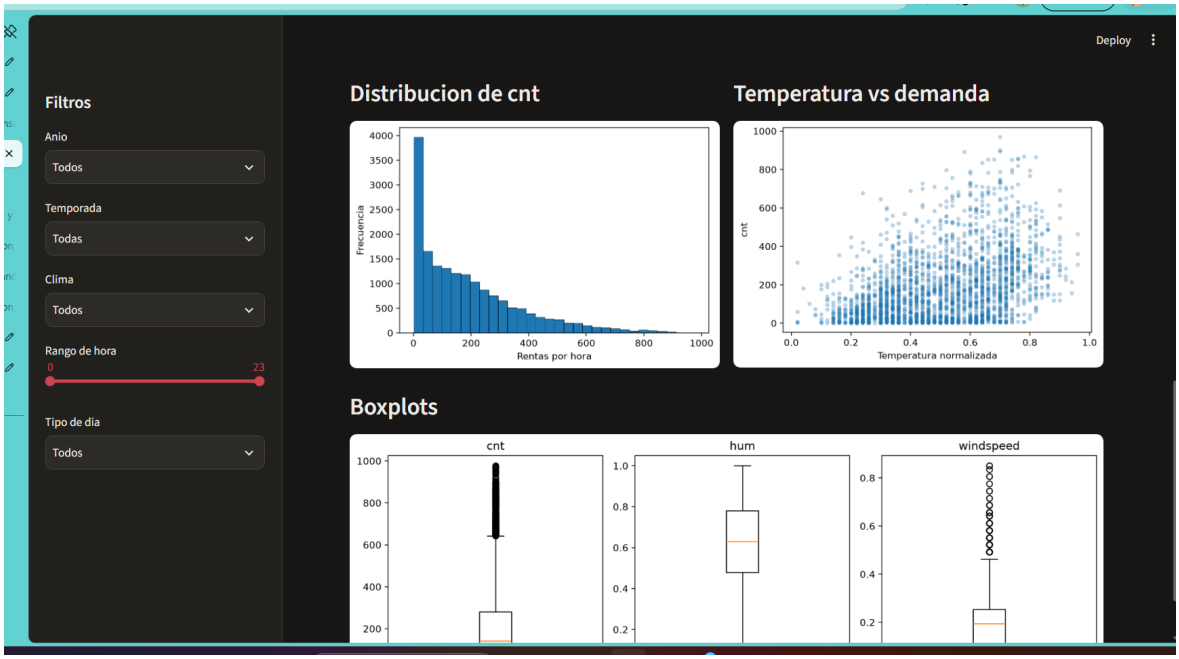


Figura 9. Visualizaciones de clima, temporada, distribucion y temperatura.

12. Referencias

Fanaee-T, H. (2013). *Bike Sharing* [Dataset]. UCI Machine Learning Repository. DOI: 10.24432/C5W894.

Fanaee-T, H., & Gama, J. (2013). Event labeling combining ensemble detectors and background knowledge. *Progress in Artificial Intelligence*.

Repositorio del proyecto: github.com/kamcr7/bike-sharing-demand