UNIVERSIDAD TECNOLOGICA DE TULA-TEPEJI

INGENIERIA EN DESARROLLO Y GESTION DE SOFTWARE

EXTRACCION DE CONOCIMIENTO EN BASES DE DATOS

RECUSAMIENTO 2026 - UNIDAD II

ACTIVIDAD DE EVALUACION 1

Exploracion y diagnostico del conjunto de datos

Alumno	Mark Alan Moya Galindo
Proyecto	Prediccion de demanda en un sistema de bicicletas compartidas
Dataset	Bike Sharing - hour.csv
Fuente	UCI Machine Learning Repository
Evidencia	Diagnostico tecnico del dataset original

El archivo original se conserva sin modificaciones en **data/raw/**.

1. Identificacion del dataset

Nombre del proyecto: Prediccion de demanda en un sistema de bicicletas compartidas.

Nombre del dataset: Bike Sharing.

Archivo principal: hour.csv.

Fuente: UCI Machine Learning Repository. El archivo original indica que los registros corresponden al sistema Capital Bikeshare de Washington D.C. durante 2011 y 2012, complementados con informacion climatica.

Formato: CSV estructurado.

Numero de registros: 17,379. **Numero de variables:** 17.

Cada fila representa una observacion horaria del sistema de bicicletas. Se incluyen variables de fecha, temporada, hora, tipo de dia, clima, temperatura, humedad, viento y conteos de usuarios.

2. Carga y exploracion inicial

El notebook carga el archivo mediante **pandas.read_csv()** y utiliza las instrucciones solicitadas: **df.head()**, **df.shape**, **df.columns**, **df.info()**, **df.dtypes** y **df.describe()**. Despues de cada resultado se agrega una interpretacion.

La exploracion confirma una estructura de 17 columnas. La mayoria de variables son numericas; **dteday** se mantiene como texto durante esta actividad para no transformar el dataset original.

3. Diccionario de datos

Variable	Descripcion	Tipo Python	Tipo / clasificacion	Unidad	Utilidad
instant	Indice del registro	int64	Cuantitativa - Discreta	Registro	Identificacion; no se propone como predictor
dteday	Fecha de observacion	object	Cualitativa/temporal - Temporal	Fecha	Analisis de tendencias por fecha
season	Temporada (1-4)	int64	Cualitativa - Nominal codificada	Categoria	Comparar demanda por temporada
yr	Anio (0=2011, 1=2012)	int64	Cualitativa - Binaria	Categoria	Comparar los dos anios
mnth	Mes (1-12)	int64	Cualitativa - Ordinal	Mes	Patrones mensuales
hr	Hora (0-23)	int64	Cualitativa - Ordinal	Hora	Patrones horarios y predictor
holiday	Indica dia festivo	int64	Cualitativa - Binaria	Categoria	Efecto de dias festivos
weekday	Dia de la semana (0-6)	int64	Cualitativa - Nominal codificada	Categoria	Patrones semanales
workingday	Dia laborable	int64	Cualitativa - Binaria	Categoria	Comparar dias laborables/no laborables
weathersit	Situacion climatica (1-4)	int64	Cualitativa - Ordinal	Categoria	Relacion entre clima y demanda
temp	Temperatura normalizada	float64	Cuantitativa - Continua	Proporcion normalizada	Predictor meteorologico
atemp	Sensacion termica normalizada	float64	Cuantitativa - Continua	Proporcion normalizada	Predictor meteorologico
hum	Humedad normalizada	float64	Cuantitativa - Continua	Proporcion normalizada	Predictor meteorologico
windspeed	Velocidad del viento normalizada	float64	Cuantitativa - Continua	Proporcion normalizada	Predictor meteorologico
casual	Usuarios casuales	int64	Cuantitativa - Discreta	Usuarios	Descripcion de demanda; evitar como predictor directo de cnt
registered	Usuarios registrados	int64	Cuantitativa - Discreta	Usuarios	Descripcion de demanda; evitar como predictor directo de cnt
cnt	Total de bicicletas rentadas	int64	Cuantitativa - Discreta	Rentas	Variable objetivo propuesta para regresion

4. Tipo y fuente de los datos

El dataset es **estructurado** porque esta organizado en filas y columnas dentro de archivos CSV.

La procedencia combina **datos transaccionales/operacionales**, derivados del uso real del sistema de bicicletas, con **datos ambientales/meteorologicos** agregados al conjunto. Por ello, los conteos reflejan actividad de personas, mientras que temperatura, humedad, viento y situacion climatica describen el contexto ambiental.

5. Diagnostico de calidad

5.1 Valores faltantes

Se aplico **df.isnull().sum()**. El resultado total es **0 valores faltantes**. Todas las variables presentan 0 faltantes y 0.00 % de ausencia.

Variable	Faltantes	Porcentaje	Tratamiento propuesto
instant	0	0.00 %	No requiere tratamiento
dteday	0	0.00 %	No requiere tratamiento
season	0	0.00 %	No requiere tratamiento
yr	0	0.00 %	No requiere tratamiento
mnth	0	0.00 %	No requiere tratamiento
hr	0	0.00 %	No requiere tratamiento
holiday	0	0.00 %	No requiere tratamiento
weekday	0	0.00 %	No requiere tratamiento
workingday	0	0.00 %	No requiere tratamiento
weathersit	0	0.00 %	No requiere tratamiento
temp	0	0.00 %	No requiere tratamiento
atemp	0	0.00 %	No requiere tratamiento
hum	0	0.00 %	No requiere tratamiento
windspeed	0	0.00 %	No requiere tratamiento
casual	0	0.00 %	No requiere tratamiento
registered	0	0.00 %	No requiere tratamiento
cnt	0	0.00 %	No requiere tratamiento

5.2 Registros duplicados

Se aplico **df.duplicated().sum()** y se obtuvieron **0 registros duplicados**. No se requiere eliminacion. Si aparecieran duplicados en una version futura, una posible causa seria una doble carga del mismo registro; antes de eliminarlos se revisarian fecha, hora y demas campos para confirmar que se trate del mismo evento.

5.3 Valores incorrectos o inconsistentes

Se comprobaron rangos esperados para temporada, anio, mes, hora, variables binarias, dia de la semana, clima y variables normalizadas. Tambien se verifico que los conteos no sean negativos y que **cnt = casual + registered**. Todas las reglas revisadas se cumplen.

Comprobacion	Resultado
season entre 1 y 4	Cumple

yr entre 0 y 1	Cumple
mnth entre 1 y 12	Cumple
hr entre 0 y 23	Cumple
holiday y workingday entre 0 y 1	Cumple
weekday entre 0 y 6	Cumple
weathersit entre 1 y 4	Cumple
temp, atemp, hum y windspeed entre 0 y 1	Cumple
casual, registered y cnt no negativos	Cumple
cnt = casual + registered	Cumple

6. Analisis estadistico inicial

Se seleccionaron **cnt**, **temp** y **hum** por su relevancia para el problema de demanda.

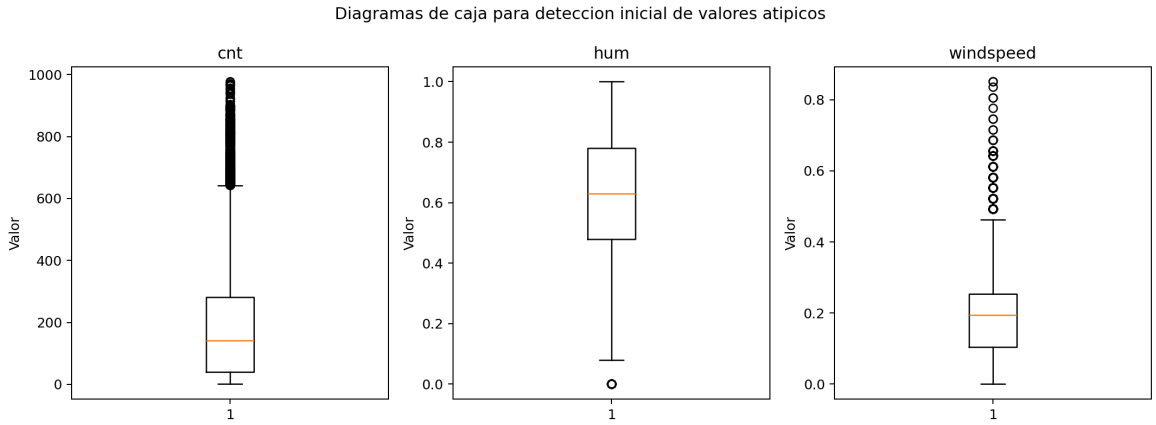
Variable	Media	Mediana	Minimo	Maximo	Desv. estandar
cnt	189.4631	142.0000	1.0000	977.0000	181.3876
temp	0.4970	0.5000	0.0200	1.0000	0.1926
hum	0.6272	0.6300	0.0000	1.0000	0.1929

La demanda **cnt** tiene media 189.46 y mediana 142.00. La diferencia entre ambas y su desviacion estandar de 181.39 muestran una distribucion con alta variabilidad y valores grandes en determinados horarios. La temperatura y humedad estan normalizadas y deben interpretarse en escala relativa.

7. Deteccion inicial de valores atipicos

Se utilizo el criterio del rango intercuartil (IQR), sin eliminar ninguna observacion.

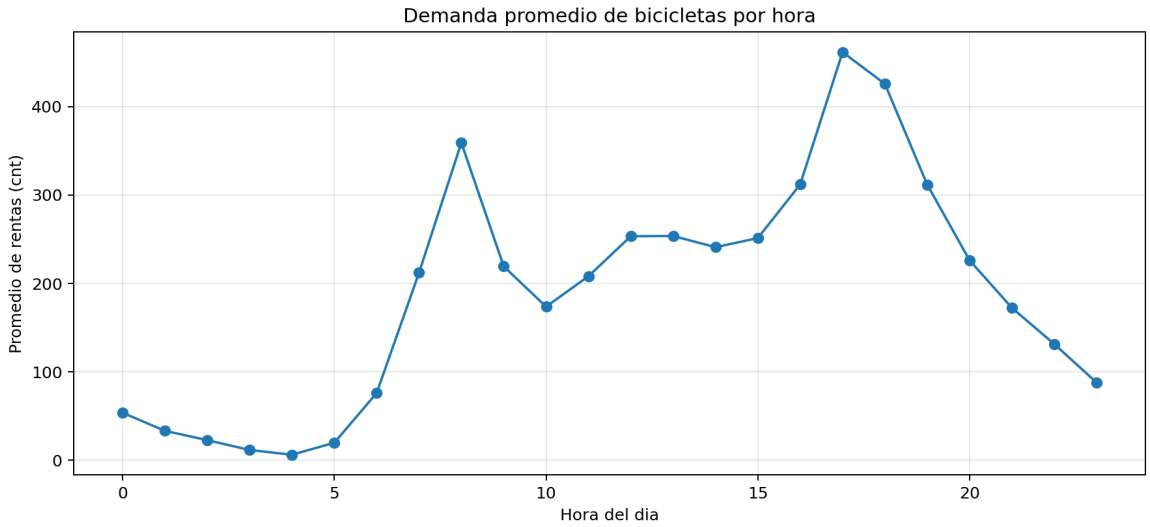
Variable	Q1	Q3	Limite inferior	Limite superior	Posibles atipicos
cnt	40.0000	281.0000	-321.5000	642.5000	505
temp	0.3400	0.6600	-0.1400	1.1400	0
hum	0.4800	0.7800	0.0300	1.2300	22
windspeed	0.1045	0.2537	-0.1193	0.4775	342



El criterio IQR identifica **505** posibles atipicos en cnt, **22** en hum y **342** en windspeed; temp no presenta atipicos bajo este criterio. Estos valores pueden ser validos y representar horas de demanda muy alta o condiciones meteorologicas extremas. Por esa razon solo se documentan.

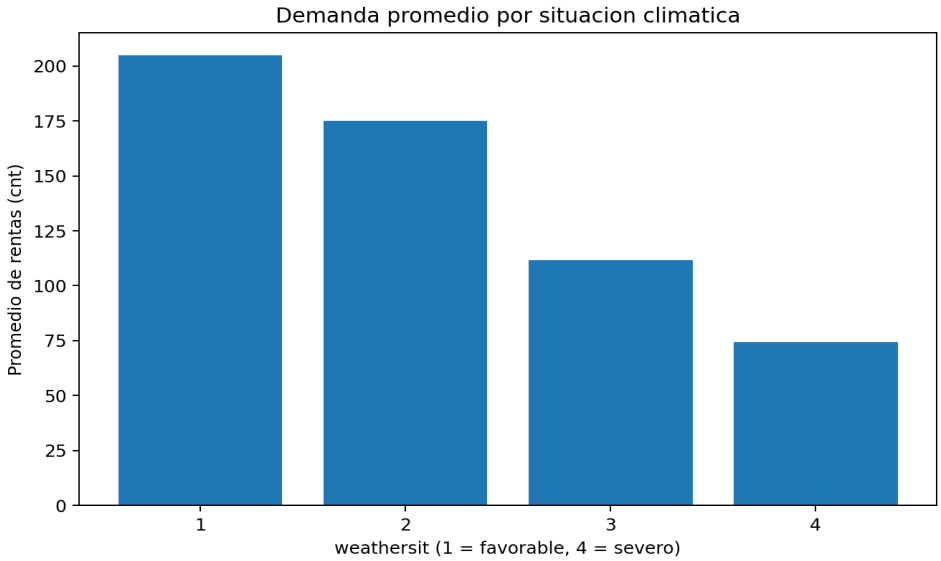
8. Visualizacion inicial

Visualizacion 1 - Demanda promedio por hora



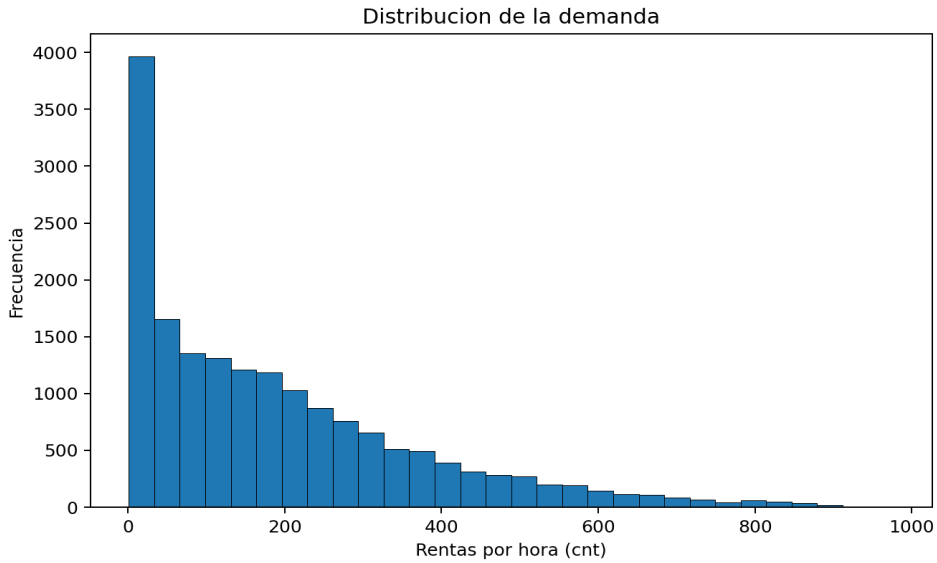
La demanda es baja durante la madrugada, aumenta por la manana y alcanza un pico muy marcado alrededor de las 17:00. Esto sugiere que el horario de traslado influye directamente en el uso del sistema.

Visualizacion 2 - Demanda promedio por clima



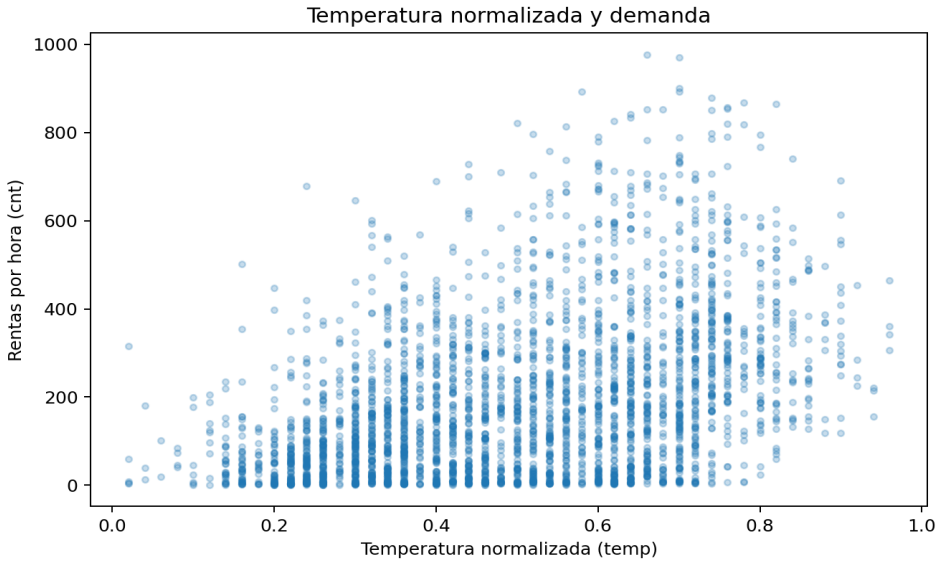
El promedio de rentas disminuye cuando las condiciones climaticas son mas adversas. Por ello, weathersit es una variable relevante para explicar la demanda.

Visualizacion 3 - Distribucion de la demanda



La distribucion muestra muchas observaciones de demanda baja o media y una cola hacia valores altos. Este comportamiento es coherente con la presencia de horas pico.

Visualizacion 4 - Temperatura y demanda



La temperatura muestra relacion con la demanda, pero no explica por si sola el total de rentas. Debe combinarse con hora, temporada, tipo de dia y clima.

9. Preparacion para analisis posteriores

Regresion. Se propone utilizar **cnt** como variable objetivo para estimar el numero total de bicicletas rentadas por hora. Las entradas sugeridas son hr, weekday, workingday, holiday, season, mnth, yr, weathersit, temp, atemp, hum y windspeed.

Clasificacion. Se propone crear posteriormente un nivel de demanda con categorias baja, media y alta. Los puntos de corte deberan definirse con un criterio reproducible y documentarse antes del entrenamiento.

Agrupamiento. Se proponen hr, weekday, season, weathersit, temp, hum, windspeed y cnt para identificar perfiles naturales de uso asociados con horario, clima y volumen de demanda.

Prevencion de fuga de informacion: casual y registered no deben usarse como predictores directos de cnt porque cnt corresponde a la suma de ambos.

10. Conclusion del diagnostico

1. ¿Que informacion contiene el dataset?
Registros horarios del uso de bicicletas, variables de calendario y condiciones meteorologicas.

2. ¿Cual es su nivel general de calidad?
Es adecuado para continuar: no presenta valores faltantes ni filas completas duplicadas y las reglas de consistencia revisadas se cumplen.

3. ¿Que problemas fueron identificados?
Se identificaron principalmente posibles valores atipicos mediante IQR; no se encontraron faltantes, duplicados ni rangos invalidos.

4. ¿Que variables requieren tratamiento?
cnt, hum y windspeed requieren revision de extremos; dteday podra convertirse a fecha en la etapa de preparacion.

5. ¿Existen valores faltantes?
No. El total detectado es 0.

6. ¿Existen registros duplicados?
No. El total detectado es 0.

7. ¿Existen valores atipicos?
Si. IQR detecta 505 en cnt, 22 en hum y 342 en windspeed. No se eliminan en esta actividad.

8. ¿Que transformaciones seran necesarias?
Conversion de fecha, posible ingenieria/codificacion de variables y evaluacion justificada de extremos durante la preparacion de datos.

9. ¿Los datos son adecuados para continuar con el Proyecto Integrador?
Si. Tienen estructura, volumen y variables suficientes para los analisis planeados.

10. ¿Que conocimiento podria obtenerse posteriormente?
Patrones de demanda por hora, clima, temporada y tipo de dia, ademas de modelos de prediccion, clasificacion y perfiles de uso.

Dashboard de apoyo

Se integro un dashboard con Streamlit que lee directamente data/raw/hour.csv. Permite filtrar por anio, temporada, clima, hora y tipo de dia; consultar datos, calidad, estadisticas, outliers y visualizaciones. El dashboard no reemplaza las evidencias solicitadas, sino que facilita la demostracion individual.

Referencias

Fanaee-T, H. (2013). Bike Sharing [Dataset]. UCI Machine Learning Repository. https://doi.org/10.24432/C5W894

Fanaee-T, H., & Gama, J. (2013). Event labeling combining ensemble detectors and background knowledge. Progress in Artificial Intelligence.

Repositorio del proyecto: https://github.com/kamcr7/bike-sharing-demand